


Analiza și procesarea datelor prin tehnici de Învățare Automată

2. Învățare Automată - concepte de bază



Universitatea
Transilvania
din Brașov

FACULTATEA DE INGINERIE ELECTRICĂ
ȘI ȘTIINȚA CALCULATOARELOR

Șef Lucrări Dr. Ing. Horia Modran

Contact: horia.modran@unitbv.ro / modranhoria@gmail.com

Tel: 0770171577

2024 - 2025



AI şi ML

Reprezentarea
Cunoştinţelor
=
Knowledge
Representation


Inteligenţa
Artificială
=
Artificial
Intelligence

Învăţarea
Automată
=
Machine
Learning



Inteligenţa Artificială

- Scopul suprem al inteligenţei artificiale este de a construi sisteme care să atingă nivelul de inteligenţă al omului
- Testul Turing: un computer prezintă un nivel de inteligenţă uman dacă un interlocutor uman nu reuşeşte să distingă, în urma unei conversaţii în limbaj natural, că vorbeşte cu un om sau cu un calculator





Învăţarea automată

- O mare parte din cercetători consideră că acest scop poate fi atins prin imitarea modului în care oamenii învaţă
- Învăţarea automată – domeniu care studiază modul în care calculatoarele pot fi înzestrate cu abilitatea de a învăţa, fără ca aceasta să fie programată în mod explicit
- În acest context, învăţarea se referă la:
 - recunoaşterea unor tipare / structuri (patterns) complexe
 - luarea deciziilor inteligente bazate pe observaţiile din date



Ce este învăţarea?

- Herbert Simon: „Învăţarea este orice proces prin care un sistem îmbunătăţeşte performanţa prin experienţă.”
- “Se spune că un program de calculator învaţă din experienţa E cu privire la o anumită clasă de sarcini T şi măsura performanţei P , dacă performanţa sa la sarcinile din T , măsurată de P , se îmbunătăţeşte cu experienţa E .




– Tom Mitchell




Tipuri de raţionament

**Raţionament deductiv
(general -> particular)**



**Raţionament inductiv
(particular -> general)**





Învăţare inductivă

- Cea mai simplă formă: învaţă o funcţie din exemple
 - f este funcţia ţintă \rightarrow un exemplu este o pereche $(x, f(x))$
- sarcină de inducţie pură:
 - având în vedere o colecţie de exemple de f , returnează o funcţie h care aproximează f .
 - se caută o ipoteză h , astfel încât $h \approx f$, având în vedere un set de exemple de antrenament
- acesta este un model foarte simplificat de învăţare reală:
 - ignoră cunoştinţele anterioare
 - presupune că sunt furnizate suficiente exemple



Aplicare

- Ce probleme pot fi rezolvate* folosind învăţarea automată?
- Se aplică în situaţii în care este foarte greu (imposibil) să definim un set de reguli de mână / să scriem un program
- Exemple de probleme unde putem aplica învăţarea automată:
 - Detectarea facială
 - Înţelegerea vorbirii
 - Prezicerea preţului acţiunilor
 - Recunoaşterea obiectelor


(*) rezolvate cu un anumit grad de acurateţe/încredere





Esenţa Învăţării Automate


- Există un tipar/şablon
- Dar nu îl putem exprima programatic / matematic
- Avem date / exemple în care regăsim acest tipar






Paradigma

Programare tradiţională



Învăţare automată





Ce este Învăţarea Automată

- **Arthur Samuel (1959)** - domeniu care oferă computerelor capacitatea de a învăţa fără a fi explicit programate
- **Kevin Murphy** – algoritmi care:
 - detectează automat modele/şabloane în date
 - utilizează tiparele descoperite pentru a prezice date viitoare sau alte rezultate de interes
- **Tom Mitchell** – algoritmi care îşi îmbunătăţesc performanţa (P) la o anumită sarcină (T) cu experienţă (E)



Scurt istoric al AI

- Anii 1950: Perceptronul lui Rosenblatt (1957)
- Anii 1960-1980: "AI Winter"
- Anii 1990: Reţelele neuronale domină, în principal datorită descoperirii algoritmului de propagare a erorii înapoi (*backpropagation*) pentru reţele cu mai multe straturi
- Anii 2000: Metodele kernel domină, în principal din cauza instabilităţii reţelelor neuronale
- Anii 2010: Revenirea la reţele neuronale, în principal datorită conceptului de învăţare profundă (deep learning)




Prezent

■ De ce funcţionează în prezent?

■ Mai multă putere
de calcul

■ Mai multe date

■ Modele mai bune





Esenţa ML

- Mii de algoritmi de învăţare automata existenţi
 - Cercetătorii publică sute de noi algoritmi în fiecare an
- Simplificând decenii de cercetare în domeniu, putem reduce învăţarea automată la:
 - **Învăţarea unei funcţii f care să mapeze un input X către un output Y , anume $f:X \rightarrow Y$**
 - Exemplu:
X: email-uri
Y: {spam, non-spam}



Esenţa ML

- Input: X (imagini, texte, email-uri...)
- Output: Y (spam sau non-spam...)
- Funcţie Target (necunoscută)
 - $f: X \rightarrow Y$ (realitatea / "adevărata" mapare)
- Date
$$(x_1, y_1), (x_2, y_2), \dots (x_N, y_N)$$
- Model
 - $g: X \rightarrow Y$
 - $y = g(x) = \text{sign}(w^T x)$




Machine Learning

- Machine learning: studiul algoritmilor care se pot îmbunătăţi automat prin experienţă şi prin utilizarea datelor
 - Cum să dezvolti un model pe baza datelor/experienţei
 - Învăţând parametri (e. g. Probabilităţi)
 - Învăţând structuri (e. g. Reţele Bayesiene)
 - Învăţând concepte ascunse (e. g. clustering)



Machine Learning și Data Mining

- Învățarea automată și Data Mining folosesc adesea aceleași metode și se suprapun în mod semnificativ
- Învățarea automată se concentrează pe predicție, pe baza proprietăților cunoscute învățate din datele de antrenament
- Data Mining se concentrează pe descoperirea de proprietăți (anterior) necunoscute în date (etapa de analiză a descoperirii cunoștințelor în baze de date)
- Data Mining folosește multe metode de învățare automată, dar cu scopuri diferite





Paradigme ale învăţării

- Învăţare supervizată: sunt furnizate date şi etichete
- Învăţare nesupervizată: sunt furnizate numai datele
- Învăţare semi- supervizată: unele (dacă nu toate) etichete sunt prezente
- Învăţare prin consolidare: un agent care interacţionează cu lumea exterioară face observaţii, ia decizii şi este recompensat sau pedepsit; ar trebui să înveţe să aleagă acţiunile în aşa fel încât să obţină o mulţime de recompense



Învăţare supervizată

- Învăţarea supervizată este sarcina de a învăţa o funcţie care mapează o intrare la o ieşire pe baza exemplelor de perechi intrare-ieşire
- deduce o funcţie din datele de antrenament etichetate
- fiecare exemplu constă dintr-un obiect de intrare şi o ieşire
- un algoritm analizează datele de antrenament şi produce o funcţie dedusă, utilizată pentru maparea de noi exemple
- scenariu optim: modelul ML va determina corect etichetele de clasă pentru instanţe nevăzute
- calitatea statistică - măsurată prin eroarea de generalizare



Terminologie

- Input: X – vector de p componente (intrări, regresor, caracteristici, variabile independente)
- Output: Y – datele de ieşire (variabila dependentă, ţintă)
- Variabilă cantitativă (ex, vârsta, înălţimea, preţ, venit, etc.) vs. variabilă calitativă (genul unei persoane, diagnostic medical, etc.)
- În problemele de regresie Y este o variabile cantitativă (ex: preţ, tensiunea arterială, etc.)
- În problemele de clasificare Y ia valori într-o mulţime finită
Datele de antrenare sunt de forma $(x_1, t_1), (x_2, t_2), \dots, (x_n, t_n)$.





Exemplu 1: Clasificare imagini


- Avem la dispoziție exemple de obiecte etichetate
- Exemplu 1: recunoașterea obiectelor din imagini cu eticheta obiectelor conținute



Car



Car



Person



Person



Dog



Exemplu 2: Filtrare spam-uri

Input: email

Output: spam/ham

Setup:

- Get a large collection of example emails, each labeled "spam" or "ham"
- Note: someone has to hand label all this data!
- Want to learn to predict labels of new, future emails

Features: The attributes used to make the ham / spam decision

- Words: FREE!
- Text Patterns: \$dd, CAPS
- Non-text: SenderInContacts
- ...



Dear Sir.

First, I must solicit your confidence in this transaction, this is by virtue of its nature as being utterly confidential and top secret. ...



TO BE REMOVED FROM FUTURE MAILINGS, SIMPLY REPLY TO THIS MESSAGE AND PUT "REMOVE" IN THE SUBJECT.

99 MILLION EMAIL ADDRESSES FOR ONLY \$99




Ok, I know this is blatantly OT but I'm beginning to go insane. Had an old Dell Dimension XPS sitting in the corner and decided to put it to use, I know it was working pre being stuck in the corner, but when I plugged it in, hit the power nothing happened.



Exemplu 3: Recunoașterea cifrelor


- Recunoașterea caracterelor scrise de mână (setul de date MNIST)
- Imagini de 28 x 28 de pixeli
- Reprezentăm o imagine ca un vector x cu 784 de componente
- Antrenăm un clasificator $f(x)$ astfel încât:
 - $f : x \rightarrow \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$






Exemplu 4: Recunoașterea facială

- O abordare constă în plimbarea unei ferestre peste imagine
- Scopul este să clasificăm fereastra într-una din cele două clase posibile: față sau non-față (transformarea problemei într-una de clasificare)





Exemplu 5: Predicţie preţ


- Scopul este de a prezice preţul la o dată din viitor, de exemplu peste câteva zile
- Acesta este un task de regresie, deoarece output-ul este unul continuu






Forme canonice

■ Clasificare



■ Regresie





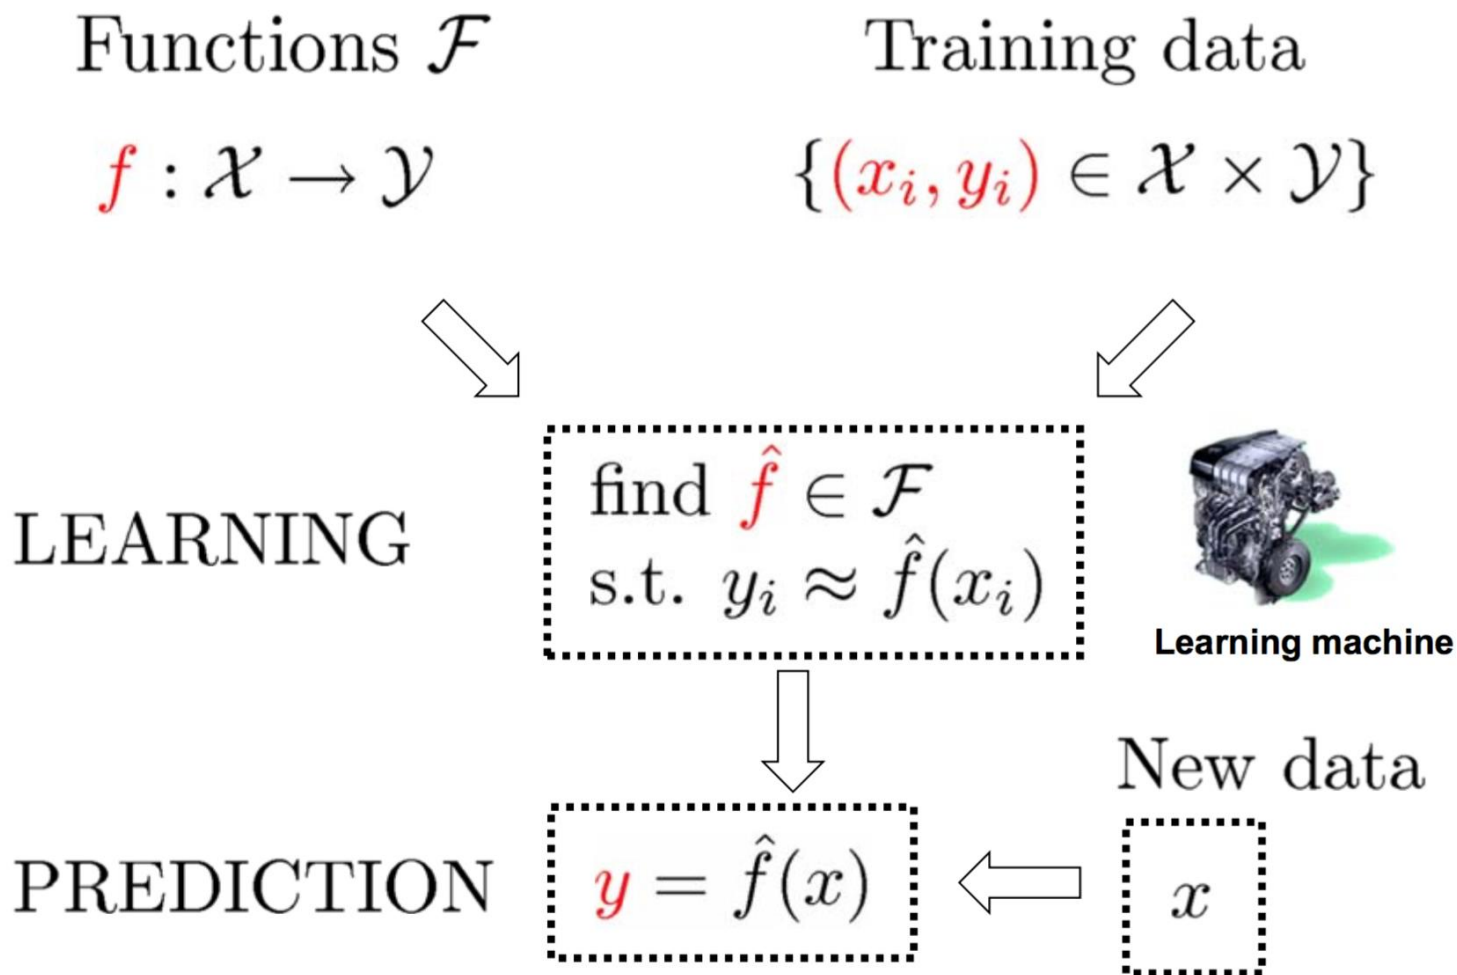
Exemple de clasificare

- În clasificare, prezicem etichetele y (clasele) pentru intrările x
- Exemple:
 - OCR (intrare: imagini, clase: caractere)
 - Diagnostic medical (input: simptome, clase: boli)
 - Evaluator automat de eseuri (input: document, clase: note)
 - Detectarea fraudei (input: activitate contului, clase: fraudă / fără fraudă)
 - direcţionarea e-mailului către serviciului clienţi
 - articole recomandate într-un ziar, cărţi
 - identificarea secvenţei de ADN şi proteine
 - investiții financiare





Paradigma de învățare supervizată



Algoritmi de învățare supervizată

- Clasificatorul Bayes naiv
- Metoda celor mai apropiați vecini
- Clasificatorul cu vectori suport (SVM)
- Metode kernel
- Rețele neuronale și învățare "deep"
- Arbori de decizie și random forests
- ... și altele






Învăţare nesupervizată

- Avem la dispoziţie exemple de obiecte fără etichete
- Exemplu 1: gruparea imaginilor după similaritate



Exemplu 2: Clustering pe MNIST

Clusterizarea aglomerativă a imaginilor MNIST

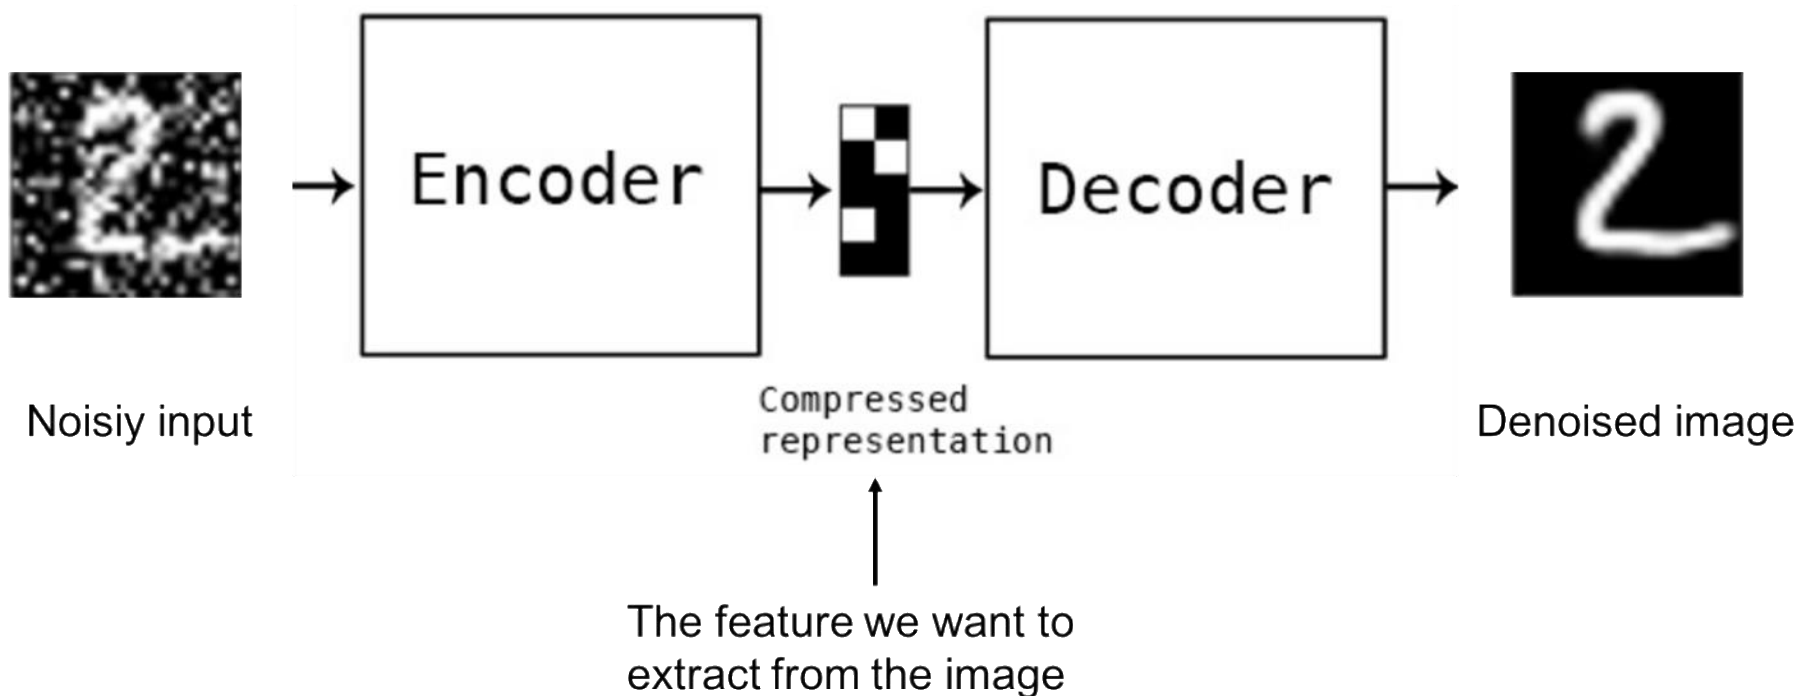


[Georgescu et al. ICIP2019]




Exemplu 3: Autoencoder

- Învăţarea de trăsături folosind principiul “bottleneck”



Exemplu 4: Hierarchical Clustering


- Gruparea mamiferelor pe familii/specii/etc.






Forme canonice

■ Grupare (*Clustering*)



■ Reducerea dimensiunii






Algoritmi de învățare nesupervizată

- ▣ K-means clustering
- ▣ Clustering ierarhic (Hierarchical Clustering)
- ▣ Analiza în componente principale (PCA)
- ▣ Modele de tip auto-encoder
- ▣ ... și altele



Învățare semi-supervizată

- Avem la dispoziție exemple de obiecte etichetate și exemple de obiecte netichetate
- Exemplu 1: recunoașterea obiectelor din imagini, unele cu eticheta obiectelor conținute



Car



Person



Dog



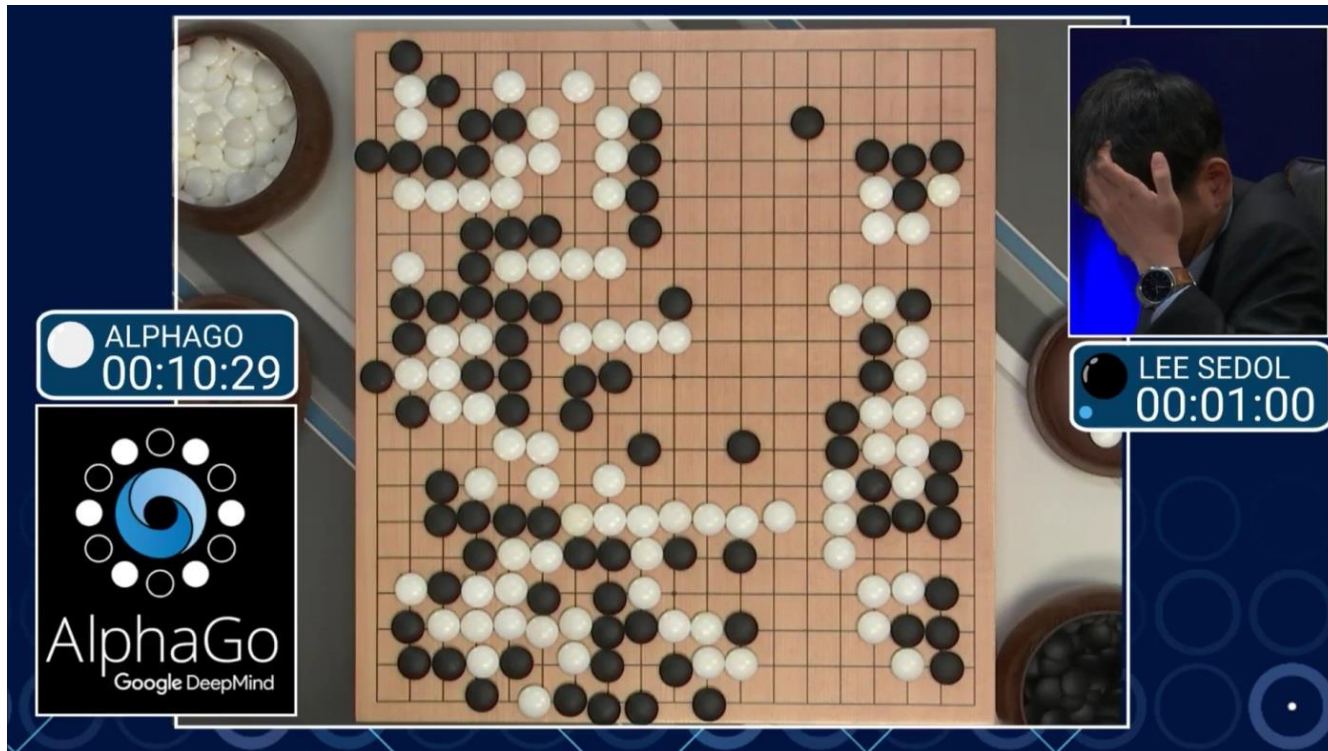
Învățare prin consolidare

- Cu ce diferă această paradigmă de învățare?
 - Sistemul învață comportamentul inteligent pe baza unei recompense (reinforcement signal)
 - Recompensa este primită după mai multe acțiuni (nu vine instant)
 - Timpul contează (datele sunt secvențiale)
 - Acțiunea sistemului influențează datele



Exemplu 1


- Exemplu 1: învăţarea jocului Go
- recompensă +/- pentru câştigarea/pierderea unui joc





Exemplu 2



- Exemplu 2: învăţarea unui robot să meargă pe bicicletă
 - recompensă \pm pentru mişcare înainte/cădere





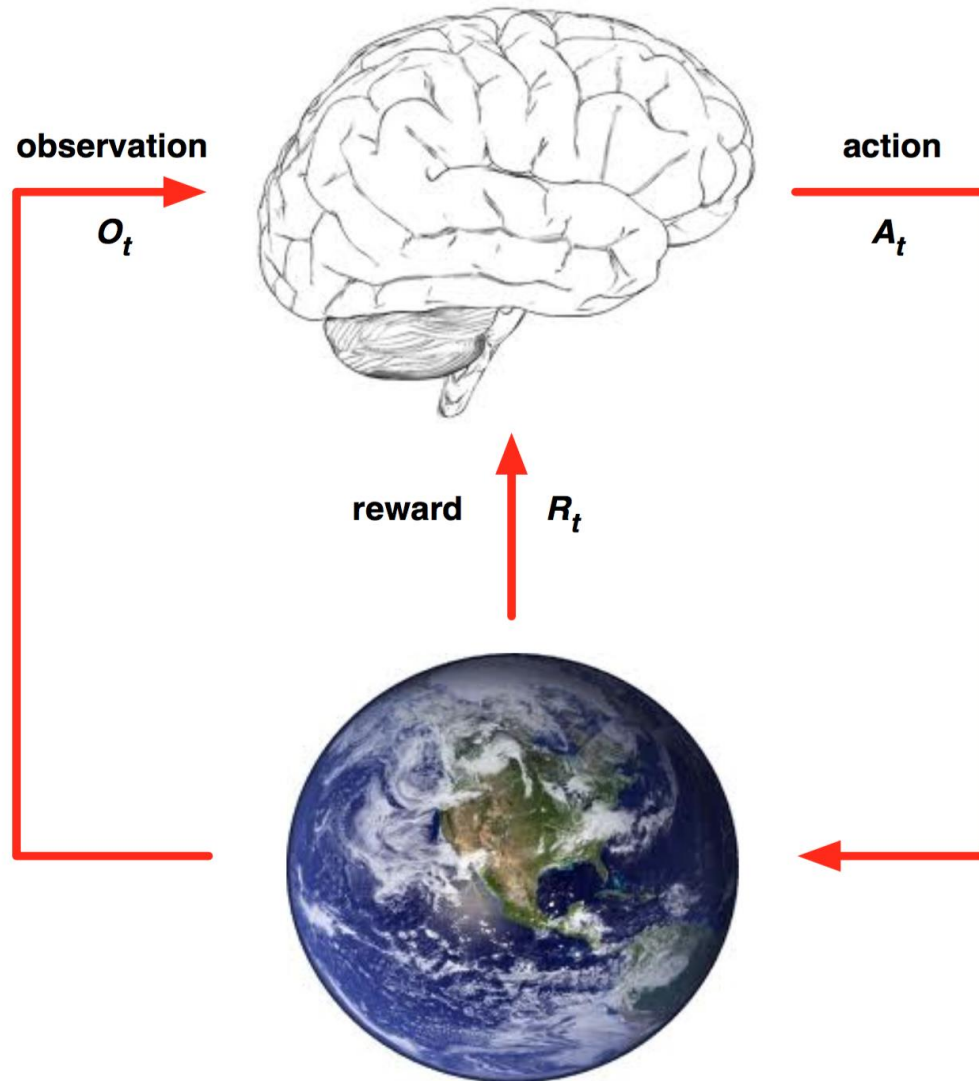
Exemplu 3

- Exemplu 3: învăţarea jocului Pong din pixeli
 - recompensă +/- pentru creşterea scorului personal/al adversarului





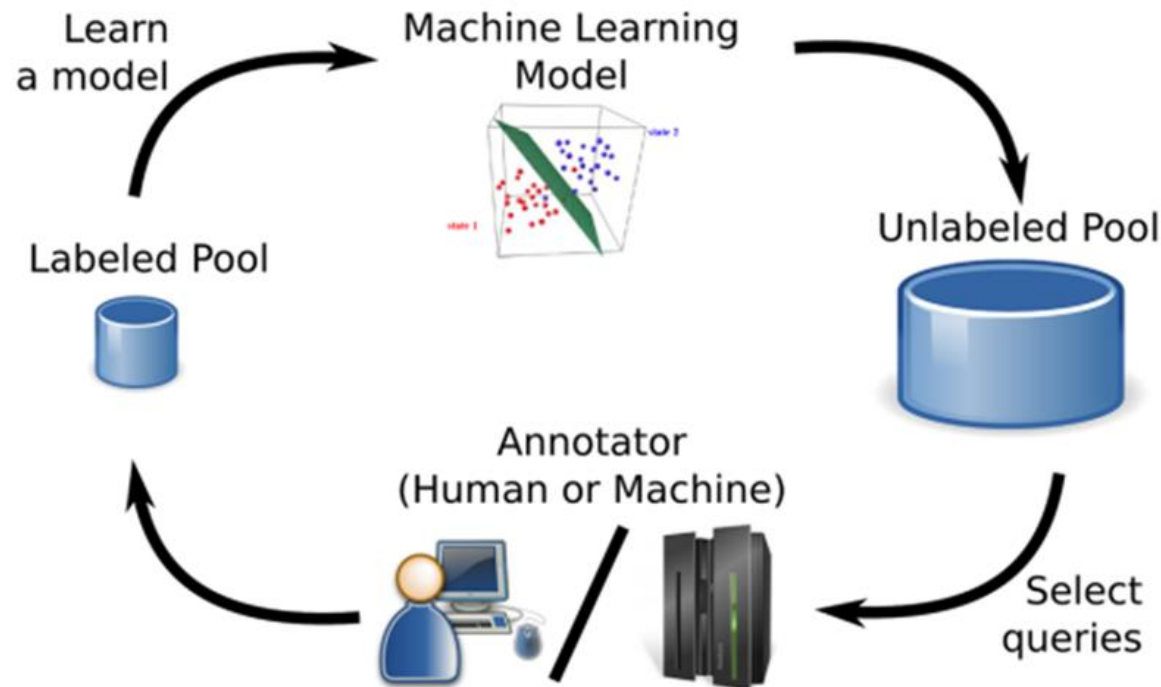
Paradigma Reinforcement Learning





Învăţare activă


- Având un set mare de exemple netichetate, trebuie să alegem un subset mult mai mic pe care să îl etichetăm pentru a obţine un clasificator cât mai bun





Învăţare prin transfer

- Pornind la un model antrenat pe un domeniu / o problemă anume, doresc să îl folosesc pentru o altă problemă / alt domeniu
- Exemplu 1: reţele neuronale convoluţionale




Alte clase de obiecte
(mai specifice),
recunoaştere facială,
clasificare de texturi, etc.



Generalizare

- Ipotezele trebuie să se generalizeze pentru a clasifica corect instanţele care nu sunt în datele de antrenament.
- simpla memorare a exemplelor de antrenament este o ipoteză consistentă care nu va generalizeaza
- Briciul lui Occam:
 - găsirea unei ipoteze simple ajută la asigurarea generalizării






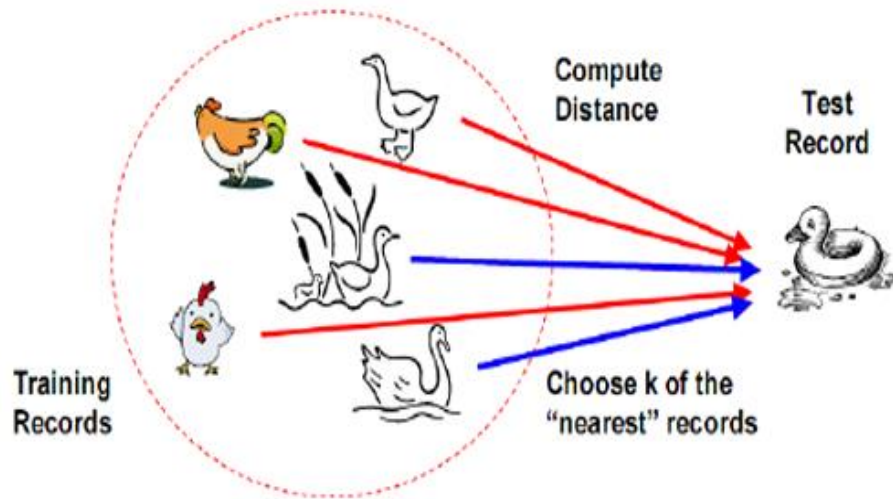
K-Nearest Neighbor (KNN)

- simplu, dar un algoritm de clasificare foarte puternic
- clasifică pe baza unei măsuri de similitudine
- neparametric
- Învățare "leneșă" (*lazy learning*)
 - nu „învață” până când nu este dat exemplul de testare
 - ori de câte ori avem date noi de clasificat, găsim K vecinii săi cei mai apropiați din datele de antrenament



K-Nearest Neighbor (KNN)

- Se folosesc cele mai apropiate k instanţe pentru a realiza clasificarea





Calcularea distanţei

■ Distanţa Euclidiană

■ Pentru a calcula distanţa dintre 2 puncte

$$x = (x_1, x_2, x_3, \dots, x_n)$$

$$y = (y_1, y_2, y_3, \dots, y_n)$$

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

$$d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2}$$

■ Observaţie

■ Pentru $n = 1$: $d(x, y) = \sqrt{(x - y)^2}$


■ Pentru $n = 2$: $d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}$


■ Pentru $n = 3$: $d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + (x_3 - y_3)^2}$



KNN: Clasificare

- clasificat prin „MAJORITY VOTES” pentru clasele vecine
- atribuit celei mai comune clase dintre cei K vecini cei mai apropiaţi ai săi (prin măsurarea „distanţei” între date)





Paşii KNN


Step 1: Determine parameter K = number of nearest neighbors

Step 2: Calculate the distance between the query-instance and all the training examples.

Step 3: Sort the distance and determine nearest neighbors based on the k -th minimum distance.

Step 4: Gather the category Y of the nearest neighbors.

Step 5: Use simple majority of the category of nearest neighbors as the prediction value of the query instance.





Exemplu KNN




Table 1. Euclidean distance matrix D listing all possible pairwise Euclidean distances between 19 samples.

	x ₁	x ₂	x ₃	x ₄	x ₅	x ₆	x ₇	x ₈	x ₉	x ₁₀	x ₁₁	x ₁₂	x ₁₃	x ₁₄	x ₁₅	x ₁₆	x ₁₇	x ₁₈	x ₁₉
x ₂	1.5																		
x ₃	1.4	1.6																	
x ₄	1.6	1.4	1.3																
x ₅	1.7	1.4	1.5	1.5															
x ₆	1.3	1.4	1.4	1.5	1.4														
x ₇	1.6	1.3	1.4	1.4	1.5	1.8													
x ₈	1.5	1.4	1.6	1.3	1.7	1.6	1.4												
x ₉	1.4	1.3	1.4	1.5	1.2	1.4	1.3	1.5											
x ₁₀	2.3	2.4	2.5	2.3	2.6	2.7	2.8	2.7	3.1										
x ₁₁	2.9	2.8	2.9	3.0	2.9	3.1	2.9	3.1	3.0	1.5									
x ₁₂	3.2	3.3	3.2	3.1	3.3	3.4	3.3	3.4	3.5	3.3	1.6								
x ₁₃	3.3	3.4	3.2	3.2	3.3	3.4	3.2	3.3	3.5	3.6	1.4	1.7							
x ₁₄	3.4	3.2	3.5	3.4	3.7	3.5	3.6	3.3	3.5	3.6	1.5	1.8	0.5						
x ₁₅	4.2	4.1	4.1	4.1	4.1	4.1	4.1	4.1	4.1	4.1	1.7	1.6	0.3	0.5					
x ₁₆	4.1	4.1	4.1	4.1	4.1	4.1	4.1	4.1	4.1	4.1	1.6	1.5	0.4	0.5	0.4				
x ₁₇	5.9	6.2	6.2	5.8	6.1	6.0	6.1	5.9	5.8	6.0	2.3	2.3	2.5	2.3	2.4	2.5			
x ₁₈	6.1	6.3	6.2	5.8	6.1	6.0	6.1	5.9	5.8	6.0	3.1	2.7	2.6	2.3	2.5	2.6	3.0		
x ₁₉	6.0	6.1	6.2	5.8	6.1	6.0	6.1	5.9	5.8	6.0	3.0	2.9	2.7	2.4	2.5	2.8	3.1	0.4	

$$d(x, y) = \sqrt{\sum_{i=1}^n (y_i - x_i)^2}$$

n– numărul de dimensiuni (în cazul nostru– 2)



ÎNTREBĂRI ?

